



Muhammad Iqbal Haikal Samia'an

UIN Imam Djamil Djambek Bukittinggi

September 25, 2026

- 1 Pendahuluan
- 2 Arsitektur Sistem
- 3 Upaya Peramalan AI
- 4 Kegagalan Rekayasa
- 5 Pivot
- 6 Pipeline Final & Hasil
- 7 Kesimpulan
- 8 Epilog: Jalan Menuju Opsi B

Tujuan

Membangun robo-advisor patuh Syariah untuk Bursa Malaysia yang:

- Menyaring semesta saham terhadap kriteria Syariah
- Mengestimasi imbal hasil dan risiko per aset
- Membangun portofolio optimal mean-CVaR dengan batasan biaya transaksi, batas kepemilikan, dan zakat

Pertanyaan yang Sebenarnya Ingin Kami Jawab

Apakah AI modern — jaringan saraf, model sekuensial mendalam, gradient boosting — dapat menghasilkan peramalan imbal hasil dengan keterampilan out-of-sample yang terbukti pada semesta saham pasar berkembang yang kecil dan heterogen?


Pada semesta ini, pada horizon ini, dengan fitur yang tersedia publik:

Tidak ada model AI yang mengalahkan baseline naif di luar sampel.

Tiga arsitektur diuji melalui tiga ronde rekayasa. Ketiganya runtuh menjadi memprediksi rata-rata historis.

Ini adalah temuan, bukan kegagalan.

Pipeline Enam Tahap Awal



- Semesta: 25 saham kapitalisasi besar Bursa Malaysia, lintas 15 sektor
- Jendela 5 tahun: $1.227 \text{ hari perdagangan} \times 25 \text{ ticker} = 30.675 \text{ baris panel}$
- 21 indikator teknikal direkayasa per ticker
- **Tahap 3 adalah tempat masalahnya bersarang.** Tahap lain berjalan.

Tahap 1 — Penyerapan Data

Yang kami ambil

- OHLCV harian via `yfinance`
- Item neraca: total aset, total utang, kas, piutang
- Klasifikasi industri (untuk penyaringan Syariah)

Sampel data langsung

- 25/25 ticker berhasil ditarik
- 1.227 hari perdagangan masing-masing
- 30.675 baris panel

Jalur cadangan

- Jika penarikan langsung gagal, buat dataset sintetis dengan skema identik (GBM + derau)
- Ini membuat pipeline *terlihat* tangguh sementara menyembunyikan bug
- **Pelajaran: fallback sintetis menyembunyikan patologi data langsung**

Tahap 2 — Penyaringan Syariah

Tier 1: Aktivitas Bisnis

Kecualikan berdasarkan sektor / industri:

- Perbankan dan asuransi konvensional (*riba*)
- Perjudian dan kasino (*maysir*)
- Pabrik bir, penyulingan, tembakau
- Senjata, hiburan dewasa, makanan non-halal

Tier 2: Rasio Keuangan (gaya SC Malaysia)

$$\frac{\text{kas \& sekuritas berbunga}}{\text{penyebut}} < 0.33 \quad \frac{\text{utang berbunga}}{\text{penyebut}} < 0.33 \quad \frac{\text{piutang + kas}}{\text{penyebut}} < 0.50$$

Pengecualian Tier 1 (6/25):

- 1155.KL Maybank
- 1295.KL Public Bank
- 3182.KL Genting
- 4715.KL Genting Malaysia
- 2836.KL Carlsberg
- 3255.KL Heineken

13 / 25 lolos kedua tier.

Tanda Bahaya (retrospektif)

Enam pengecualian ini baru berjalan benar *setelah* perbaikan bug besar. Pada run pertama, Maybank dan Carlsberg lolos diam-diam. Kita akan kembali ke sini.

Tiga arsitektur. Tiga set fitur. Satu pertanyaan:

Apakah ada yang mengalahkan “prediksi rata-rata historis”?

Ronde	Model	Fitur	Vonis
1	MLP per-aset	19 teknikal	0/17
2	CNN-LSTM	19 tek. + 6 fundamental	0/13
3	GBM lintas-seksi	19 tek. + 6 fundamental	0/13

Arsitektur

- `MLPRegressor(hidden=(32,16))`
- `StandardScaler` pada fitur
- Fit per-ticker
- Target: log return 21 hari ke depan
- Split train/test 80/20

Hipotesis

- Indikator teknikal mengandung sinyal prediktif untuk imbal hasil horizon pendek

Hasil

- **10 dari 17** ticker menghasilkan ramalan yang mentok di clip $\pm 60\%$ tahunan
- Output ANN mentah mencapai $\pm 500\%$
- `val_rmse` melebihi std target pada sebagian besar ticker
- Clip adalah satu-satunya alasan kolom terlihat terbatas

Ronde 1 — Gejala Saturasi

Ticker	exp_return_ann	val RMSE
2836.KL	0.6000	0.1212
5168.KL	0.6000	0.4508
3255.KL	0.6000	0.1368
8869.KL	0.6000	0.3943
5211.KL	0.6000	0.1000
3689.KL	0.1806	0.1808
4707.KL	0.1089	0.1192
...	...	...
1155.KL	-0.6000	0.2099
3026.KL	-0.6000	0.1101

Diagnosis

10/17 ramalan tepat bernilai ± 0.60 — nilai guard-rail. Model tidak memiliki daya prediktif; clip adalah satu-satunya hal yang membuat output tampak wajar.

Ronde 2 — CNN-LSTM + Fundamental

Arsitektur

- CNN 1-D atas sumbu fitur (interaksi lokal)
- LSTM atas sumbu waktu (dinamika temporal)
- Panjang sekuens = 60 hari perdagangan
- PyTorch, ~ 10.000 parameter

Fitur tambahan

- Momentum revisi EPS
- Kedalaman revisi
- Pergeseran rekomendasi
- Riwayat kejutan laba
- Estimasi pertumbuhan konsensus

Hasil

- Tingkat keterisian fundamental: **0/13** ticker memiliki $\geq 3/6$ fitur fundamental terisi
- Rata-rata bobot kepercayaan model: **0.00**
- Sumber ramalan: 0 CNN-LSTM / 3 campuran / 10 rata-rata historis
- Output CNN-LSTM mentah: **-4.5** hingga **+5.5** tahunan (tidak masuk akal)

Yang Kami Pelajari

Bahkan dengan penyusutan dan arsitektur yang lebih ekspresif, model tidak dapat melewati ambang

Kerangka yang Benar

Alih-alih memprediksi imbal hasil 21 hari *absolut* tiap aset (didominasi faktor pasar yang tak terprediksi), prediksi *peringkat lintas-seksi* dari imbal hasil ke depan tiap aset dalam semesta. Buang faktor pasar, simpan hanya sinyal relatif.

- Model: HistGradientBoostingRegressor
- Fitur: skor Van der Waerden rank-z, dihitung dalam tiap tanggal
- Target: peringkat lintas-seksi dari log return 21 hari ke depan
- Split walk-forward dengan embargo 21 hari untuk mencegah kebocoran
- Metrik: Koefisien Informasi (IC) Spearman, dirata-rata per tanggal
- Aturan keputusan: percaya model hanya jika $t(\text{IC}) \geq 2.0$

$$\text{IC awal} = +0.075, t = 8.03$$

Terlihat seperti sinyal yang kuat. Melewati ambang yang wajar.

Tapi itu salah.

Dari mana angka itu berasal

466 observasi IC harian. Statistik t standar:

$$t = \frac{\bar{\text{IC}}}{\sigma_{\text{IC}}/\sqrt{n}} = \frac{0.075}{0.325/\sqrt{466}} \approx 8.03$$

Semuanya bergantung pada asumsi bahwa $n = 466$ observasi *independen*.

Dosa Statistik

Setiap IC tanggal menggunakan **imbal hasil 21 hari ke depan**. Tanggal berurutan berbagi 20 dari 21 hari informasi. 466 “observasi” hanya membawa kandungan informasi sekitar $466/21 \approx 22$ observasi yang benar-benar independen.

Kuantitas	Naif	Koreksi tumpang tindih
IC rata-rata	+0.0087	+0.0087
Std IC	0.3248	0.3248
n efektif	466	22.2
Statistik t	+0.58	+0.13
Ambang kepercayaan	2.0	2.0

Kesimpulan

“Sinyal” sepenuhnya artefak dari ukuran sampel yang digelembungkan. Dengan n efektif yang benar, IC

Kegagalan pemodelan diperparah oleh bug rekayasa yang membuat hasil antara *tampak* masuk akal.

Empat kategori, masing-masing disamarkan oleh fallback data sintetis atau oleh lapisan output tanpa batas.

Bug #1 — Nilai Tak Hingga di Panel Fitur

Gejala

- `ValueError: Input X contains infinity`
- Diangkat dalam `StandardScaler.transform`
- Membuat Tahap 3 crash untuk setiap ticker

Akar masalah

- `vol_roc10 = volume.pct_change(10)`
- Saham mid-cap Bursa punya hari volume-nol (penghentian perdagangan)
- Pembagian dengan nol $\rightarrow \pm\infty$

Mengapa jalur sintetis melewatkannya

Volume sintetis dihasilkan sebagai `np.abs(rng.normal(...))` — *selalu positif*. Bug hanya bisa muncul pada data nyata.

Perbaikan

`feats.replace([np.inf, -np.inf], np.nan)` di akhir `compute_indicators_for_ticker`. NaN tingkat baris ditangani oleh `dropna()`.

Bug #2 — Ketidakcocokan Kosakata Penyaringan Syariah

Gejala

- Maybank dan Carlsberg *lolos* penyaringan Syariah
- Keduanya muncul di portofolio akhir
- **Kegagalan kepatuhan**, bukan sekadar bug

Akar masalah

- Penyerapan langsung memberi label ulang via industry Yahoo: "Excluded (brewers)"
- NON_COMPLIANT_SECTORS berisi "Brewery"
- Kedua himpunan tidak pernah beririsan $\Rightarrow$ Tier 1 selalu mengembalikan True

Mengapa tersembunyi

Jalur sintetis menyalin label sektor apa adanya dari DEFAULT_UNIVERSE, jadi "Brewery" cocok dan Tier 1 *tampak* bekerja. Jalur langsung memakai kosakata yang berbeda.

Perbaikan

NON_COMPLIANT_INDUSTRY_KEYWORDS sekarang memetakan substring Yahoo *langsung ke label kanonik*, dengan asersi saat impor agar kedua kosakata tetap sinkron.

Bug #3 — Vol di-Z-Score Sebelum Dipakai sebagai Vol

Gejala

- `exp_vol_ann` setiap ticker tercetak sebagai 0.0300 — batas bawah clip
- Optimizer menumpuk ke ticker dengan imbal hasil tertinggi seolah-olah mereka juga yang paling rendah risiko

Akar masalah

- `vol21_ann` di-z-score lintas-seksi
- Vol yang di-z-score punya rata-rata ≈ 0 lintas ticker
- `clip(0, 0.03, 0.90) → 0.03` untuk semua ticker

Perbaikan

Simpan vol mentah per-ticker *sebelum* transformasi lintas-seksi, dalam dictionary ber-key ticker:

```
raw_vol_by_ticker =  
panel.groupby(...).mean().to_dict()
```

Pelajaran meta

Z-score lintas-seksi menghancurkan skala absolut fitur apa pun. Jika tahap hilir memerlukan nilai *asli*, snapshot sebelum transformasi.

Bug #4 — Bias Melihat ke Depan pada Fundamental

Masalahnya

Fitur fundamental diambil sebagai *snapshot tunggal dari hari ini*, lalu disiarkan ke seluruh lima tahun riwayat:

$$\text{panel}[c] = \text{snap.get}(t, \text{NaN}) \quad \forall \text{tanggal}$$

Jadi pada 2021-01-04 model melihat estimasi EPS konsensus 2026.

- Dalam backtest yang sesungguhnya, ini adalah kebocoran.
- Ini tidak membatalkan hasil negatif (model tetap gagal), tetapi berarti evaluasi IC *bukan* uji OOS yang sebenarnya.
- Upaya masa depan untuk membangun model yang bekerja harus menggunakan basis data point-in-time dengan as-of join yang benar.

Resolusi pada Opsi A

Provider fundamental dihapus dari pipeline default. Ia tetap ada sebagai hook ekstensi yang terdokumentasi bagi siapa pun yang memiliki sumber point-in-time yang layak.

Tiga arsitektur diuji. Dua set fitur. Dua formulas target berbeda (absolut, lintas-seksi).

Semua gagal.

Pada titik tertentu, mengganti arsitektur lagi bukan solusi — itu cara menghindari temuan.

Kami mengambil keputusan

Berhenti mencoba meramal. Laporkan statistik historis sebagai mana adanya, beri label jujur, dan biarkan optimizer bekerja dengan apa yang benar-benar ada.

Apa yang berubah

- Tahap 3 diubah nama: “Estimasi Imbal Hasil Historis”
- Nama kolom: `exp_return_ann` → `hist_return_ann`
- Tidak ada fitting model pada Tahap 3
- Setiap ticker mendapat rata-rata imbal hasil historis dan volatilitas terealisasi sendiri

Apa yang tetap

- Struktur pipeline enam tahap
- Penyaringan Syariah (Tier 1 + Tier 2)
- Optimizer mean-CVaR dengan biaya transaksi, batas kepemilikan, dan zakat
- Kuesioner pemprofilan investor
- Uji stres (dirumuskan ulang — slide berikutnya)

Sebelum (rusak)

- Kalikan estimasi imbal hasil tengah dengan fraksi skenario
- Untuk portofolio berimbang hasil rendah:


$$\begin{aligned}\text{GFC} &= 0.05 \times 3.84\% \\ &= \mathbf{+0.19\%}\end{aligned}$$

- Setiap skenario menghasilkan imbal hasil *positif*
- Bukan uji stres — hanya hiasan

Setelah (benar)

- Hitung vol portofolio dari matriks kovarians:
 $\sigma_p = \sqrt{w^\top (\text{DCD}) w}$
- Terapkan drawdown berganda- σ dikalibrasi dari pergerakan ekuitas puncak-ke-dasar historis:

Skenario	Kelipatan σ
Guncangan suku bunga 2022	1.25
COVID 2020	1.70
Dot-com 2000	2.45
GFC 2008	2.75



- Tahap 3 (disorot) sekarang menjadi tahap *statistik deskriptif*, bukan tahap peramalan
- Setiap kolom output diberi label sumbernya (`estimate_source = "historical_5y"`)
- Tidak ada komponen dalam pipeline yang mengklaim keterampilan prediktif yang tidak dimilikinya

Tahap 3 — Output Estimasi Historis

Ticker	hist_return_ann	hist_vol_ann	n_obs
5211.KL Sunway	+23.80%	24.64%	1.183
3336.KL IJM	+15.42%	29.91%	1.185
5285.KL SD Guthrie	+13.18%	25.12%	1.183
8869.KL Press Metal	+8.81%	27.68%	1.185
3816.KL MISC	+7.71%	16.55%	1.185
1961.KL IOI	+7.48%	20.27%	1.185
6033.KL Petronas Gas	+5.72%	14.79%	1.185
3026.KL Dutch Lady	+0.71%	15.21%	1.185
3689.KL F&N	+0.60%	21.37%	1.185
4707.KL Nestlé	−5.34%	17.75%	1.185
5183.KL Petronas Chemicals	−9.68%	33.27%	1.183
7113.KL Top Glove	−25.83%	48.94%	1.185
5168.KL Hartalega	−32.56%	48.88%	1.183

Rentang imbal hasil [−32.56%, +23.80%]. Rentang vol [14.79%, 48.94%]. Ini adalah rata-rata lima tahun ke belakang, **bukan** ramalan.

Tahap 5 — Portofolio Optimal

Ticker	Bobot	Sektor	hist ret.	hist vol.
5211.KL Sunway	30.00%	Konglomerat	23.80%	24.64%
3816.KL MISC	20.97%	Pelayaran Laut	7.71%	16.55%
5285.KL SD Guthrie	17.22%	Makanan Kemasan	13.18%	25.12%
6033.KL Petronas Gas	14.41%	Minyak & Gas	5.72%	14.79%
3336.KL IJM	12.45%	Konglomerat	15.42%	29.91%
1961.KL IOI	4.96%	Makanan Kemasan	7.48%	20.27%

Metrik tingkat portofolio

Imbal hasil ekspektasi (bruto, tahunan)	14.14%
Imbal hasil ekspektasi (neto biaya + zakat)	11.49%
CVaR @ keyakinan 90%	8.78%
Turnover dari posisi awal	100.00%
Seretan biaya transaksi	0.15%
Zakat tahunan	2.50%

Tahap 6 — Hasil Uji Stres

Skenario	Kelipatan σ	Imbal hasil portofolio
Guncangan suku bunga 2022	1.25	-16.18%
COVID 2020	1.70	-22.01%
Dot-com 2000	2.45	-31.72%
GFC 2008	2.75	-35.60%

Mengapa ini sekarang kredibel

- Diterapkan pada volatilitas *portofolio itu sendiri* ($\sigma_p = 12.95\%$)
- Kelipatan skenario dikalibrasi dari drawdown ekuitas puncak-ke-dasar yang nyata
- Tanda benar: setiap krisis menghasilkan kerugian
- Klien dapat melihat estimasi tengah (+14.14%) dan rantai krisis (−35.60%) berdampingan

Mengapa AI Gagal di Sini — Lima Alasan

- ❶ **Ukuran sampel.** Horizon 21 hari pada data 5 tahun memberi ≈ 250 observasi non-tumpang-tindih per ticker. Model dengan 10.000 parameter tidak dapat dibatasi oleh itu.
- ❷ **Rasio sinyal-terhadap-derau.** Sinyal ekuitas nyata memiliki $IC \approx 0.03\text{--}0.05$. Mendeteksinya membutuhkan *ratusan* lintas-seksi independen. Jendela tumpang tindih mengurangi n efektif kami sebesar $\sqrt{21}$.
- ❸ **Kualitas fitur.** Fitur fundamental (estimasi analis, revisi) tidak tersedia pada kualitas data ritel. **0/13** ticker memiliki $\geq 3/6$ fitur terisi.
- ❹ **Hipotesis nol pasar efisien.** Imbal hasil 21 hari pada saham likuid kapitalisasi besar pada dasarnya tidak dapat diprediksi dari teknikal publik. Ini bukan bug — ini temuan yang benar.
- ❺ **Kapasitas overfitting.** MLP, CNN-LSTM, dan gradient boosting semuanya memiliki parameter lebih banyak daripada yang dapat dibatasi data. Ketiganya runtuh menjadi memprediksi rata-rata pelatihan.

Kapan Deep Learning AI Layak?

Layak

- **N besar:** 10^4+ sampel independen
- **Sinyal stasioner:** bahasa, visi, sistem fisik
- **Fitur kaya:** berdimensi tinggi, padat, terisi baik
- **Lantai derau rendah:** galat prediksi didominasi bias, bukan varians
- **Benchmark tersedia:** baseline naif yang dapat dikalahkan dan diukur

Tidak Layak

- **N kecil:** hanya puluhan lintas-seksi
- **Pasar efisien:** sinyal terkubur di bawah derau
- **Fitur jarang:** data pasar berkembang kualitas ritel
- **Lantai derau tinggi:** model menyesuaikan derau, bukan sinyal
- **Tanpa benchmark:** tidak dapat membedakan model yang bekerja dari yang overfit

Peramalan ekuitas patuh Syariah di Bursa Malaysia memenuhi **kelima kotak “tidak layak”**.

Hal paling berharga yang bisa dilakukan sebuah model adalah memberi tahu Anda kapan jangan memakainya.

Mekanisme penyusutan yang kami bangun — campur output model dengan rata-rata historis, dibobot oleh keterampilan out-of-sample — **bekerja dengan benar**. Ia mendeteksi bahwa ketiga arsitektur memiliki keterampilan *negatif* dan menetralkannya.

Tugas pipeline bukan untuk benar. Tugasnya untuk jujur. Pada metrik itu, ia berhasil.

1. Fallback sintetis menyembunyikan patologi data nyata

Setiap bug yang hanya muncul pada data langsung (volume tak hingga, hari volume-nol, fundamental hilang) tidak terlihat pada jalur sintetis. Jika Anda punya fallback, Anda harus menguji jalur langsung *secara spesifik*.

2. Pergeseran kosakata antar lapisan adalah risiko kepatuhan

Bug penyaringan Syariah diam-diam meloloskan Maybank dan Carlsberg ke portofolio akhir. Asersi saat impor antara dua kosakata sekarang menjadi satu-satunya alasan bug itu tidak dapat terulang.

3. Transformasi lintas-seksi menghancurkan skala absolut

Z-score fitur untuk model juga men-z-score fitur itu untuk semua tahap hilir. Jika tahap berikutnya butuh nilai asli, snapshot sebelum transformasi.

4. Jendela tumpang tindih menggembungkan statistik t sebesar $\sqrt{\text{horizon}}$

Selalu gunakan koreksi n efektif atau estimator Newey–West HAC saat mengevaluasi ramalan pada

AI bukan pelarut universal.

Ia memerlukan:

- Data pada skala yang tidak selalu disediakan masalah
- Rasio sinyal-terhadap-derau yang tidak dijamin domain
- Fitur yang hanya ada jika Anda mampu membelinya
- Benchmark yang memberi tahu Anda kapan harus berhenti

Ketika kondisi itu gagal,
**keputusan rekayasa yang benar
adalah berhenti, memberi label jujur, dan mengirimkan apa
yang bekerja.**

Empat Vektor Perbaikan untuk Opsi B

Opsi A adalah jawaban untuk data yang kita punya.
Opsi B masih mungkin — tetapi memerlukan data yang berbeda.

Vektor	Dampak pada t -stat	Biaya
1. Perluas semesta saham	3–4×	Gratis
2. Fundamental point-in-time	3–5×	Tinggi
3. Riwayat historis lebih panjang	2×	Sedang
4. Fitur baru dari OHLCV	1.5–2×	Gratis

Intuisi Matematis

$$t = \frac{\overline{IC}}{\sigma_{IC}/\sqrt{n_{\text{eff}}}}, \quad n_{\text{eff}} \propto N_{\text{aset}} \times T_{\text{tahun}}$$

Meningkatkan jumlah aset atau tahun riwayat menaikkan t -stat secara *akarnya*. Meningkatkan kualitas

Situasi saat ini

- 25 ticker awal
- Setelah penyaringan Syariah: 13 ticker
- $n_{\text{eff}} \approx 22$ per tahun

Target realistis

- ~ 950 ticker di Bursa
- Syariah: ~ 650 – 700 ticker
- Likuiditas min. (Rp 1 juta/hari): ~ 300 – 400
- Kap. min. RM 500 juta: ~ 150 – 200

Efek

- N_{aset} : $13 \rightarrow 150$ ($\sim 11\times$)
- Baris panel: $30.675 \rightarrow 184.050$
- t -stat efektif bisa naik 3 – $4\times$

Peringatan

Menambah aset *tidak likuid* menambah derau, bukan sinyal. Gunakan filter likuiditas tegas. Lebih baik 100 ticker likuid daripada 300 ticker dengan volume tidak stabil.

Vektor 2 — Fundamental Point-in-Time

Masalah saat ini

0/13 ticker memiliki $\geq 3/6$ fitur fundamental terisi. Yang berhasil ditarik pun bukan point-in-time — snapshot hari ini disiarkan ke seluruh riwayat (*look-ahead bias*).

Sumber	Cakupan	Biaya	API
Bloomberg Terminal	200+ ticker	Sangat tinggi	BLPAPI
Refinitiv Eikon	200+ ticker	Sangat tinggi	TR API
Capital IQ	150+ ticker	Tinggi	S&P API
EODHD	50–80 ticker	Sedang	REST
Alpha Vantage	~50 ticker	Sedang	REST
Yahoo Finance	~30 ticker	Gratis	yfinance

Yang dibutuhkan

Basis data yang bisa menjawab: “Pada 2023-01-15, apa estimasi EPS FY1 konsensus untuk 5211.KL?” dengan jawaban *pada tanggal itu*, bukan apa yang kita ketahui sekarang.

Vektor 3 — Riwayat Historis Lebih Panjang

Situasi saat ini

- 5 tahun riwayat
- 1.227 hari perdagangan
- Satu rezim pasar (post-COVID, suku bunga naik)

Target

- 15–20 tahun riwayat
- ~ 3.500 – 5.000 hari perdagangan
- 3–4 rezim pasar berbeda (GFC, pemulihan, COVID, kenaikan suku bunga)

Efek

- T : $5 \rightarrow 20$ tahun ($4\times$)
- t -stat naik $2\times$ (akar dari 4)
- Model melihat beberapa krisis, bukan satu

Caveat

Rezim berubah. Model yang dilatih 2003–2008 mungkin tidak relevan untuk 2020-an. Gunakan *walk-forward rolling window*, bukan panel statis.

Vektor 4 — Fitur Baru dari Data yang Sudah Ada

Prinsip

Bahkan tanpa data baru, OHLCV masih menyimpan sinyal yang belum kita ekstrak. Ini area yang paling sering diabaikan.

Fitur	Konsep	Referensi
IVOL	Volatilitas residual vs indeks	Ang et al. (2006)
Downside beta	Beta pada hari pasar turun	Ang et al. (2006)
Skewness 60h	Kemiringan distribusi return	Bali et al. (2011)
Momentum netral-sektor	Momentum relatif sektor	Moskowitz & Grinblatt (1999)
Amihud illiquidity	$ r /\text{volume}$, 60h	Amihud (2002)
Volume-price divergence	Korelasi ΔV vs ΔP	Granville (1963)

Mengapa ini membantu

Bukti literatur: strategi *kombinasi faktor* memiliki IC lebih stabil daripada faktor tunggal. Dengan 6–8 faktor terpilih, IC cross-sectional bisa mencapai 0.05–0.08 *tanpa* data fundamental.

Vektor 5 — Rezim Target yang Berbeda

Saat ini

- Horizon: 21 hari
- Target: log return kontinu
- Kerugian: MSE

Alternatif

- **Horizon 6–12 bulan:** momentum historisnya lebih kuat di horizon ini
- **Klasifikasi biner:** “akankah saham mengalahkan median semesta?”
- **Prediksi kuantil:** regresi kuantil atau *ranking*

Mengapa horizon lebih panjang lebih baik

- Pada 21 hari, *reversal* jangka pendek mendominasi, dan itu sangat noisy
- Pada 6–12 bulan, *momentum* dan *value* mendominasi, dan kedua faktor ini jauh lebih stabil (Jegadeesh & Titman 1993)

Mengapa klasifikasi lebih mudah

Target biner menghindari masalah outlier return ekstrem yang merusak MSE. Log-loss jauh lebih stabil untuk model kecil.

Urutan Eksekusi yang Disarankan

Prioritas	Vektor	Usaha	Biaya
1	Perluas semesta ke 100–200 ticker	Sedang	Gratis
2	Fitur baru dari OHLCV	Sedang	Gratis
3	Riwayat historis 15–20 tahun	Rendah	Sedang
4	Fundamental point-in-time	Tinggi	Tinggi
5	Ganti horizon target	Rendah	Gratis

Logika

- ➊ Langkah 1 & 2 bisa dieksekusi minggu ini, tanpa biaya
- ➋ Jika setelah keduanya t -stat masih < 1.0 , hentikan. Opsi A adalah jawaban final.
- ➌ Jika t -stat naik ke 1.0–2.0, layak diselidiki lebih lanjut, tetapi belum cukup untuk produksi
- ➍ Hanya jika > 2.0 dengan validasi walk-forward, pertimbangkan Opsi B sebagai pengganti Opsi A

Prediksi ekspektasi dari AI memerlukan tiga hal sekaligus:

Banyak data	lebih banyak aset, lebih banyak tahun
Fitur kuat	fundamental point-in-time atau rekayasa OHLCV yang canggih
Benchmark jujur	selalu bandingkan dengan baseline naif

Jika ketiganya tidak tersedia,
**Opsi A adalah keputusan rekayasa yang benar —
bukan kegagalan, tetapi kejujuran.**

Terima Kasih

Ada pertanyaan?